Lineare Regression

Jan-Philipp Kolb

20 Juni 2017

Die lineare Regression

Maindonald - Data Analysis

- ► Einführung in R
- Datenanalyse
- Statistische Modelle
- Inferenzkonzepte
- ► Regression mit einem Prädiktor
- ► Multiple lineare Regression
- Ausweitung des linearen Modells

Lineare Regression in R - Beispieldatensatz

John H. Maindonald and W. John Braun

DAAG - Data Analysis and Graphics Data and Functions

```
install.packages("DAAG")
```

```
library("DAAG")
data(roller)
```

help on roller data:

?roller

Das lineare Regressionsmodell in R

Schätzen eines Regressionsmodells:

```
roller.lm <- lm(depression ~ weight, data = roller)</pre>
```

So bekommt man die SchĤtzwerte:

summary(roller.lm)

Coefficients:

##

```
##
## Call:
## lm(formula = depression ~ weight, data = roller)
##
## Residuals:
## Min 1Q Median 3Q Max
## -8.180 -5.580 -1.346 5.920 8.020
##
```

(Intercept) = 2.0871 4.75/3 = 0.430 0.67227

Estimate Std. Error t value Pr(>|t|)

Summary des Modells

summary(roller.lm)

```
##
## Call:
## lm(formula = depression ~ weight, data = roller)
##
## Residuals:
     Min 1Q Median 3Q
                              Max
##
## -8.180 -5.580 -1.346 5.920 8.020
##
## Coefficients:
             Estimate Std. Error t value Pr(>|t|)
##
## (Intercept) -2.0871 4.7543 -0.439 0.67227
         2.6667 0.7002 3.808 0.00518 **
## weight
## ---
## Signif. codes: 0 '***' 0.001 '**' 0.05 '.' 0.3
```

##
Residual standard error: 6.735 on 8 degrees of freedom

R arbeitet mit Objekten

- ▶ roller.lm ist nun ein spezielles Regressions-Objekt
- ► Auf dieses Objekt können nun verschiedene Funktionen angewendet werden

```
predict(roller.lm) # Vorhersage
```

resid(roller.lm) # Residuen

```
## 1 2 3 4 5
## 2.979669 6.179765 6.713114 10.713233 12.046606 14.180
## 8 9 10
## 18.180121 24.046962 30.980502
```

5

7.9533944


1 2 3 4 ## -0.9796695 -5.1797646 -1.7131138 -5.7132327

7 8 9 10 ## 8.0199738 -8.1801213 5.9530377 -5.9805017

Residuenplot

- Sind Annahmen des linearen Regressionsmodells verletzt?
- Dies ist der Fall, wenn ein Muster abweichend von einer Linie zu erkennen ist.
- ▶ Hier ist der Datensatz sehr klein


```
plot(roller.lm,1)
```



Residuenplot

Wenn die Residuen normalverteilt sind sollten sie auf einer Linie liegen.

```
plot(roller.lm,2)
```




Regressionsdiagnostik mit Basis-R

Ein einfaches Modell

```
N <- 5
x1 <- rnorm(N)
y <- runif(N)</pre>
```

Die Dichte der beiden Vektoren

```
par(mfrow=c(1,2))
plot(density(x1))
plot(density(y))
```




Modellvorhersage machen

```
mod1 \leftarrow lm(y\sim x1)
pre <- predict(mod1)</pre>
у
## [1] 0.80546933 0.19499632 0.24129626 0.02413855 0.16144;
pre
##
                                                              5
```

0.2836019 0.2699229 0.2916785 0.2542092 0.3279318

Regressionsdiagnostik mit Basis-R

```
plot(x1,y)
abline(mod1)
segments(x1, y, x1, pre, col="red")
```



Beispieldaten Luftqualität

library(datasets)
?airquality

airquality (datasets)

New York Air Quality Measurements

Description

Daily air quality measurements in New York, May to September 1973.

Usage

airquality

Format

A data frame with 154 observations on 6 variables.

```
[,1] Ozone numeric Ozone (ppb)
[,2] Solar R numeric Solar R (lang)
```

Das visreg-Paket

##

Ein Modell wird auf dem airquality Datensatz geschĤtzt

```
install.packages("visreg")
library(visreg)
```

```
summary(fit)
##
## Call:
```

fit <- lm(Ozone ~ Solar.R + Wind + Temp, data = airquality)


lm(formula = Ozone ~ Solar.R + Wind + Temp, data = airq ## ## Residuals:


```
Min 10 Median
                           30
##
                                 Max
## -40.485 -14.219 -3.551 10.097 95.619
```

Coefficients: Estimate Std. Error t value Pr(>|t|)

Visualisierung

```
par(mfrow=c(2,1))
visreg(fit)
```






Und dann mit visreg visualisiert.


► Zweites Argument - Spezifikation erklärende Variable für Visualisierung

```
visreg(fit, "Wind", type = "contrast")
```



Visualisierung mit dem Paket visreg


```
visreg(fit, "Wind", type = "contrast")
```



Das visreg-Paket

▶ Das Default-Argument für type ist conditional.

```
visreg(fit, "Wind", type = "conditional")
```



Regression mit Faktoren

Call:

Mit visreg können die Effekte bei Faktoren visualisiert werden.

```
airquality$Heat <- cut(airquality$Temp, 3,
    labels=c("Cool", "Mild", "Hot"))
fit.heat <- lm(Ozone ~ Solar.R + Wind + Heat,
    data = airquality)
summary(fit.heat)
##
```


```
## lm(formula = Ozone ~ Solar.R + Wind + Heat, data = airqu
##
```


Residuals: Min 1Q Median 3Q Max ## ## -33.473 -12.794 -2.686 8.461 107.035

Coefficients: ## Estimate Std. Error t value Pr(>|t|)

Effekte von Faktoren

```
par(mfrow=c(1,2))
visreg(fit.heat, "Heat", type = "contrast")
visreg(fit.heat, "Heat", type = "conditional")
```





Das Paket visreg - Interaktionen

Wind

```
airquality$Heat <- cut(airquality$Temp, 3,
labels=c("Cool", "Mild", "Hot"))
fit <- lm(Ozone ~ Solar.R + Wind * Heat, data = airquality;
summary(fit)

##
## Call:
## lm(formula = Ozone ~ Solar.R + Wind * Heat, data = airquality;
##
## Residuals:</pre>
```

Min 1Q Median 3Q Max ## -34.472 -11.640 -1.919 7.403 102.428 ## ## Coefficients:

Estimate Std. Error t value Pr(>|t|)
(Intercept) 4.48042 17.38219 0.258 0.797102
Solar.R 0.07634 0.02137 3.572 0.000538 ***


1 34860

0 043 0 965458

0 05854


Steuern der Graphikausgabe mittels layout

```
visreg(fit, "Wind", by = "Heat",layout=c(3,1))
```




Das Paket visreg - Interaktionen overlay

fit <- lm(Ozone ~ Solar.R + Wind * Heat, data = airquality
visreg(fit, "Wind", by="Heat", overlay=TRUE, partial=FALSE</pre>




Das Paket visreg - visreg2d

```
fit2 <- lm(Ozone ~ Solar.R + Wind * Temp, data = airquality
visreg2d(fit2, "Wind", "Temp", plot.type = "image")</pre>
```



Das Paket visreg - surface

```
visreg2d(fit2, "Wind", "Temp", plot.type = "persp")
```



Linkliste - lineare Regression

- Regression r-bloggers
- ▶ Das Komplette Buch von Faraway- sehr intuitiv geschrieben.
- ▶ Gute Einführung auf Quick-R
- Multiple Regression
- Basis Regression How to go about interpreting regression cofficients